

**UNIVERSIDAD DEL VALLE DE GUATEMALA**

Modelación y Simulación - CC2017

Sección 21

Ing. Luis Alberto Suriano



*Excelencia que trasciende*

**DEL VALLE**  
GRUPO EDUCATIVO

## Laboratorio No. 10

Pablo Orellana	21970
Diego Leiva	21752
Gustavo González	21438

**GUATEMALA, 22 de octubre del 2024**

## **Ejercicio 1**

**Responda las siguientes preguntas**

**1. ¿Cómo se puede verificar que una cadena MCMC ha alcanzado su estado estacionario y por qué esto es importante?**

- Para verificar si una cadena MCM alcanzó su estado estacionario, se pueden usar herramientas como trace plots, donde se pueden ver si las muestras se estabilizan alrededor de la distribución objetivo. También se pueden usar pruebas estadísticas como la autocorrelación de muestras, esta debe disminuir conforme aumenta el número de iteraciones. Otra forma puede ser un periodo burn-in, que básicamente es el descartar las primeras muestras de la cadena porque pueden estar influenciadas por las condiciones iniciales arbitrarias (Davies, 2020b).

**2. ¿En qué situaciones es preferible usar el Muestreador de Gibbs sobre Metropolis-Hastings?**

- El Muestreador de Gibbs es preferible sobre Metropolis-Hastings cuando es posible obtener fácilmente las distribuciones condicionales de cada variable, como puede ser en un modelo con varias variables, porque Gibbs puede alternar entre ellas de manera eficiente, mientras que Metropolis-Hastings es más flexible, pero hay mayor número de rechazos y requiere de distribuciones bien afinadas. Entonces Gibbs se usa cuando las distribuciones son manejables (Schmidt, 2020) (Davies, 2020a).

**3. ¿Cómo afecta la elección de la distribución de propuesta en la eficiencia del Algoritmo de Metropolis-Hasting y cómo afecta la tasa de aceptación de las muestras?**

- Dicha elección afecta significativamente su eficiencia. Una distribución propuesta mal calibrada puede resultar en una alta autocorrelación entre muestras o en una tasa de aceptación baja, esto hace que la cadena tarde más en explorar. El equilibrio ideal estaría en las tasas de aceptación, entre 23% y 44%, dependiendo de la dimensionalidad del problema, tasas muy altas indican que las propuestas son muy conservadoras, mientras que tasas bajas llevan a que la cadena se quede atrapada en un subconjunto del espacio de estados (Davies, 2020a) (Robert, 2015).

## Referencias

Davies, R. (2020a). *Simulation—Lectures 7—MCMC: Metropolis Hastings*.

Davies, R. (2020b). *Simulation—Lectures 8—MCMC: Gibbs*.

Robert, C. P. (2015). *The Metropolis–Hastings algorithm*. Ar5iv.

<https://ar5iv.labs.arxiv.org/html/1504.01896>

Schmidt, M. (2020). *CPSC 540: Machine Learning—Metropolis-Hastings*